

基于混合深度学习框架的超宽带雷达睡眠呼吸暂停检测方法

贺蓓^{1†}, 黄锦阳^{1*}, 刘鑫¹, 赵鹏¹, 崔丰麒², 郭宇童¹, 王萌¹, 黎歆雨¹, 赵思蕊³

(1. 合肥工业大学计算机与信息学院, 合肥 230601; 2. 中国科学技术大学信息科学技术学院, 合肥 230026;

3. 中国科学技术大学计算机科学与技术学院, 合肥 230026; †共同第一作者。* 通讯作者电子邮箱 hjy@hfut.edu.cn)

摘要: 超宽带 (UWB, ultra-wideband) 雷达能通过感知胸腔微动实现非接触式睡眠呼吸暂停检测。针对现有方法仅进行有无呼吸暂停的粗粒度二分类或依赖整夜统计的严重程度评估、无法刻画事件瞬态严重程度的问题, 提出了一种细粒度睡眠呼吸暂停检测方法 (FG-SAD, fine-grained sleep apnea detection), 实现对睡眠呼吸暂停事件的瞬态严重程度的精细评估。为缓解细粒度分类中严重的类别不平衡问题, 设计了结合少数类数据增强与类别加权损失的双层缓解策略, 提升模型对稀有类别的识别能力。为解决呼吸信号跨尺度时序异质性强的问题, 级联局部形态特征与全局上下文建模, 设计了混合多尺度形态感知网络 (HMSMP-Net, hybrid multi-scale morphology perception network), 使网络具备对复杂呼吸动态的多尺度感知能力。自建临床雷达数据集上的实验结果表明, FG-SAD 分类准确率达 92.34%, 宏平均 F1 分数较现有方法平均提升 10.26%, 验证了所提方法在细粒度睡眠呼吸暂停检测中的有效性与优越性。数据集与代码的开源地址是: <https://github.com/kairidao/FG-SAD>。

关键词: 超宽带雷达; 睡眠呼吸暂停; 细粒度分级; 混合深度学习

中图分类号: TN95; TP391

文献标志码: A

A hybrid deep learning approach for sleep apnea detection using UWB radar

HE Bei^{1†}, HUANG Jinyang^{1*}, LIU Xin¹, ZHAO Peng¹, CUI Fengqi², GUO Yutong¹,
WANG Meng¹, LI Xinyu¹, ZHAO Sirui³

1. School of Computer Science and Information Engineering, Hefei University of Technology, Hefei 230601, China;

2. School of Information Science and Technology, University of Science and Technology of China, Hefei 230026, China;

3. School of Computer Science and Technology, University of Science and Technology of China, Hefei 230026, China;

† Co-first author. * Corresponding author: Jinyang Huang (Email: hjy@hfut.edu.cn).

Abstract: Ultra-wideband (UWB) radar has been utilized for non-contact sleep apnea detection by sensing subtle thoracic movements. To address the limitation that existing methods only performed coarse-grained binary classification of the presence or absence of sleep apnea or relied on overnight statistics for severity assessment, which were unable to characterize the transient severity of apnea events, a fine-grained sleep apnea detection method (FG-SAD) was proposed. To alleviate the severe class imbalance problem in fine-grained classification, a dual-level mitigation strategy combining minority class data augmentation and class-weighted loss was designed to improve the recognition capability for rare classes. To address the strong cross-scale temporal heterogeneity of respiratory signals, local morphological feature extraction and global contextual modeling were cascaded, and a hybrid multi-scale morphology perception network (HMSMP-Net) was designed to provide multi-scale perception capability for complex respiratory dynamics. Experimental results on a self-constructed clinical radar dataset demonstrated that FG-SAD achieved a classification accuracy of 92.34%, while the macro F1-score was improved by 10.26% on average compared with existing methods. The proposed method is effective and superior for fine-grained sleep apnea detection. Our dataset and code are available at: <https://github.com/kairidao/FG-SAD>.

Key words: Ultra-wideband (UWB) radar, sleep apnea, fine-grained classification, hybrid deep learning

0 引言

睡眠呼吸暂停 (SA, sleep apnea) 是临床上最常见的睡眠呼吸障碍疾病^[1]。它不仅影响患者的睡眠质量, 还会诱

发心血管疾病以及代谢性疾病^[2-5]。健康人群在正常的睡眠过程中也会发生短暂的生理性呼吸暂停，这意味着仅仅依靠判断有没有发生呼吸暂停的粗粒度的二分类方式，难以有效地指导临床决策^[6]。近年来多项研究揭示了呼吸暂停的发作频次与患者的心血管疾病致死率之间的正相关关系，推动临床研究的关注点从事件的有无转向细粒度的时序与频次信息^[7]。比如呼吸暂停低通气指数（AHI, apnea-hypopnea index）已被确立为评估睡眠呼吸暂停严重程度的核心指标^[8]。因此，如何从长时序的呼吸生理信号中捕获短时呼吸暂停异常事件的细粒度信息，已经成为睡眠医学评估与智能诊断研究中的关键问题。

多导睡眠图（PSG, polysomnography）是诊断睡眠呼吸暂停的金标准^[9]。但在实际临床应用中，这种方法流程复杂、成本高、需要专业人员操作，且会干扰患者的正常睡眠行为^[10-14]，这些因素使得许多潜在患者不能获得及时有效的筛查和诊断。非接触式超宽带（UWB, ultra-wideband）雷达感知技术的出现，为解决上述问题提供了一种可行的替代方案^[15]。UWB 雷达具有高时间分辨率与良好的穿透性，能够以非接触的方式捕获到人体胸腔呼吸运动以及体动的细微变化^[16-19]，还具有低功耗、低成本等优势，适用于长期居家环境中的持续健康监测^[20-21]。近年来，基于 UWB 雷达的睡眠呼吸监测研究受到了广泛关注。部分研究聚焦于异常事件的粗粒度检测，例如文献[22]构建了基于 UWB 雷达的医疗物联网系统，实现了包括睡眠呼吸暂停在内的多种异常状态检测。文献[23]采用自监督学习方法缓解雷达睡眠数据标注不足的问题，提高了模型的泛化能力。这些研究证明了 UWB 雷达用于非接触式睡眠监测的可行性，但其主要目标仍集中于判断是否存在呼吸暂停事件，没有充分刻画病理事件的严重程度变化。为满足临床筛查的需求，一些研究开始探索基于 UWB 雷达的睡眠呼吸暂停严重程度评估。例如，文献[24]通过估计整夜 AHI 并与 PSG 进行一致性对比，实现了四级严重程度评估。文献[8]则引入 CNN-Transformer 混合架构，对正常呼吸、低通气和呼吸暂停事件进行识别，再基于整夜 AHI 完成严重程度分级。尽管这些工作已初步涉及了严重程度评估，但其判定过程主要依赖整夜事件的宏观统计，难以反映呼吸暂停事件在时间维度上的动态特征以及短时病理风险变化。因此，有必要进一步研究面向短时窗口的细粒度睡眠呼吸暂停严重程度检测方法。

然而，在 UWB 睡眠监测中实现短时细粒度呼吸暂停严重程度判别仍面临严峻挑战。一方面，细粒度等级划分导致严重的类别分布不平衡。那些严重程度较高、发生频率较低的呼吸暂停事件在数据中所占比例要比正常的呼吸样本低。受此影响，模型在训练过程中更容易偏向数量较多的正常样本，因此，模型识别少数关键类别的能力就被削弱了。另一方面，UWB 雷达采集到的呼吸信号不仅包含秒级的局部波动，还包含分钟级的长程演变趋势，因此呼吸信号呈现出显著的跨尺度时序异质性。现有方法难以同时兼顾这两种时序动态特征。因此，亟需构建一种能够协同实现局部形态感知与全局上下文建模的细粒度检测框架，以实现呼吸暂停瞬态严重程度的精细量化。

为了应对上述挑战，本文提出了一种基于 UWB 雷达的细粒度睡眠呼吸暂停检测方法（FG-SAD, fine-grained sleep apnea detection），从数据分布校准和网络架构设计两个方面来做协同设计，旨在实现复杂呼吸动态的精细刻画。针对临床睡眠呼吸暂停数据集中普遍存在的类别不平衡挑战，本文设计了一种双层缓解策略。本文首先在数据层面对少数类数据进行了增强，扩展稀有类别的样本分布，从而提升训练数据的多样性。在算法层面，本文使用基于类别加权的交叉熵损失计算方法，在优化过程中赋予那些稀有的类别更高的权重，迫使模型更多地关注这些样本。此外，针对呼吸信号跨尺度时序异质性强这一挑战，本文设计了一种混合多尺度形态感知网络架构（HMSMP-Net, hybrid multi-scale morphology perception network），把基于金字塔卷积的局部形态感知前端和统一的全局上下文建模后端进行结合，以实现雷达信号的高精度表征。模型前端利用并行的一维卷积（Conv1D, one-dimensional convolution）在不同感受野下提取呼吸波形的多分辨率局部特征，后端采用 Mamba 来高效建模长时序的状态演化过程，同时结合双向门控循环单元（BiGRU, bidirectional gated recurrent unit）实现对双向边界的精确刻画。临床实测数据集上的实验结果表明，FG-SAD 方法在睡眠呼吸暂停检测任务上取得了优于现有基线方法的整体性能。

本文的主要贡献总结如下：

（1）提出了一种基于 UWB 雷达的非接触式睡眠呼吸暂停分层框架 FG-SAD，面向短时细粒度呼吸暂停严重程度判别构建五分类任务，实现对呼吸暂停严重程度的细粒度评估。该框架从数据与架构层面进行协同设计，兼具强鲁棒与高精度的特性，能够准确地表征出呼吸暂停事件不同严重程度之间的病理差异，为临床睡眠呼吸暂停严重程度评估提供更加精细化的依据。

（2）针对临床数据中普遍存在的类别不平衡问题，设计了一种双层缓解策略，将少数类数据增强与类别加权损失相结合，提升模型对呼吸暂停事件中的稀有类别的识别敏感性和鲁棒性。此外，考虑到呼吸信号跨尺度时序异质性，设计了高精度的混合多尺度形态感知网络 HMSMP-Net，该网络由局部形态感知前端与全局上下文后端构成，能够精确地刻画复杂的呼吸动态特征。

（3）在医院临床环境中进行数据采集，构建了包含五类严重程度标签的 UWB 雷达睡眠呼吸暂停数据集。在该

数据集上对 FG-SAD 进行了全面的评估实验。结果显示，FG-SAD 的性能超过了现有的方法，它的分类准确率为 92.34%，宏平均 F1 分数为 82.06%。还通过详细的消融实验验证了 FG-SAD 中的双层缓解策略及 HMSMP-Net 中各个模块的有效性。

1 雷达信号感知模型




图 1 UWB 雷达信号模型与采集示意图

本文主要利用 UWB 雷达信号中纳秒级脉冲信号的时间分辨特性实现高精度睡眠呼吸暂停检测。发射端周期性发送 UWB 短时脉冲序列，第 m 帧的发射信号通过对基带高斯脉冲进行重复发射生成。接收端采集的回波信号为多路径反射的叠加，经过时间对齐与采样处理后，得到反映信道特性的脉冲响应信号^[25] (CIR, channel impulse response)。基于 UWB 雷达系统信号模型如图 1 所示，第 m 帧的发射信号可以表示为：

$$S(t) = \sum_{m=1}^M p(t - (m-1)T_p) \quad (1)$$

其中， M 表示发射脉冲的数量， T_p 是脉冲重复周期。接收信号可表示为：

$$R_m^{\text{frame}}(t) = \sum_{n=1}^N a_n p_m(t - \tau_n) + n_0(t) \quad (2)$$

其中， a_n 以及 τ_n 是第 n 个散射点的振幅衰减和传播时延。 N 是散射中心的数量， $n_0(t)$ 是传输噪声。传播时延由目标距离决定：

$$\tau_n = \frac{2R_n}{c} \quad (3)$$

其中， R_n 为目标距离， c 为光速。进一步地，本文采用了式 (4) 的 CIR 模型来表征信道的行为：

$$h(t) = \sum_{n=1}^N a_n \delta(t - \tau_n) + v(t) \quad (4)$$

其中，第一项代表确定性多径分量，第二项代表弥散多径分量。连续多帧雷达回波信号可以用矩阵形式表示：

$$\mathbf{R}_{m,n} = R_m^{\text{frame}}(nT_f), m = 1, 2, \dots, M; n = 1, 2, \dots, N \quad (5)$$

其中， T_f 是帧信号的采样周期。 m 维代表慢时间维度，反映目标随时间的动态变化。 n 维代表快时间维度，可以通过双向飞行时间映射为距离维数。由于 UWB 雷达具备高时间分辨率、低功耗和抗干扰能力，该方法在睡眠呼吸监测、非接触式生命体征检测以及在复杂环境下的人体感知等场景中具有广泛的应用前景^[26]。

2 方法设计

本节主要介绍 FG-SAD 的整体流程。如图 2 所示，本文提出的非接触式细粒度睡眠呼吸暂停检测方法主要包含三个模块，分别是数据采集与预处理、双层类别不平衡缓解策略以及网络架构 HMSMP-Net，旨在实现精细化、强鲁棒和高精度的睡眠呼吸暂停检测。在数据采集阶段使用 UWB 雷达传感器采集原始 I/Q 雷达信号。接下来，本

文基于事件频次分级对采集到的信号进行信号质量增强与细粒度标注，以抑制环境干扰并提取出干净的呼吸波形。处理后的时序数据会被输入到混合网络模型当中，这样系统就能实现对睡眠呼吸暂停事件的细粒度分类。




图 2 基于 UWB 雷达的 FG-SAD 方法的非接触式睡眠呼吸暂停检测概述

2.1 雷达信号预处理

本节针对 UWB 雷达原始回波信号中存在的体动干扰与环境噪声等问题，进行了系统性的信号预处理与样本标注构建。首先将原始复数 I/Q 雷达回波处理成神经网络可以使用的幅度数据，在此基础上，本文采用基于卡尔曼滤波的异常值剔除方法和小波阈值去噪技术得到保留呼吸细节特征的高质量信号。在完成信号预处理步骤后，为进一步实现细粒度分级，本文基于事件频次分级对样本进行细粒度标注，将连续波形分割为 2 分钟窗口并标注为 0~4 五个等级，为后续分类模型提供干净、标注精细的输入数据。

2.1.1 基于卡尔曼残差的异常值剔除方法

在连续检测场景下，UWB 雷达通过捕获人体呼吸导致的胸腔的微小运动进行睡眠呼吸暂停识别，其幅度通常为毫米级。然而人在睡眠过程中的翻身、手脚抽动等宏观运动产生的位移通常都是厘米级，甚至分米级的。以及有时会因为设备的状态的变化而导致出现一些异常的波动。这些异常情况不可避免的引入了非生理性的脉冲干扰，抑制了正常的呼吸成分的幅值表征。为此，本文采用了基于卡尔曼滤波^[27] (kalman filter) 的异常值剔除方法。

本文将胸壁运动建模为慢时间维度下的恒速运动模型，第 k 个采样时刻的状态向量表示为：

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{w}_k \quad (6)$$

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k \quad (7)$$

其中， $\mathbf{A} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$ 为状态转移矩阵， Δt 为慢时间采样间隔，观测矩阵 $\mathbf{H} = [1 \ 0]$ 表示 UWB 雷达仅能观测到位移量。

$\mathbf{w}_k$ 和 $\mathbf{v}_k$ 分别为协方差 $\mathbf{Q}$ 和 $\mathbf{R}$ 的过程噪声和观测噪声。根据卡尔曼预测结果，计算观测残差及其协方差：

$$\tilde{\mathbf{y}}_k = \mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_{k|k-1} \quad (8)$$

$$\mathbf{S}_k = \mathbf{H}\mathbf{P}_{k|k-1}\mathbf{H}^T + \mathbf{R} \quad (9)$$

基于此，本文构建了归一化残差平方 ε_k 作为判断该时刻数据点是否异常的标准：

$$\varepsilon_k = \tilde{\mathbf{y}}_k^T \mathbf{S}_k^{-1} \tilde{\mathbf{y}}_k \quad (10)$$

由于系统观测的位置为一维信号，所以统计量 ε_k 理论上服从自由度为 1 的 χ^2 分布。当统计量小于设定阈值时，采

用标准卡尔曼滤波更新状态；否则判定该采样点为异常值，并利用预测值代替当前观测值完成信号重构。

2.1.2 小波阈值信号降噪算法

剔除异常值后，信号仍易受到环境噪声、多径效应以及突发体动等多种因素的干扰^[28]。因此，本文采用小波阈值去噪方法^[29](WTD, wavelet threshold denoising)对雷达信号进行降噪处理。这里选择了 Daubechies 小波基函数(db6)对信号进行多尺度分解。每个尺度都用 Donoho 阈值进行去噪，该阈值的定义为：

$$\lambda(j) = \sigma_T \sqrt{2\log(I) / \log(j+1)} \quad (11)$$

其中， $\lambda(j)$ 和 j 分别代表了分解时的波长和尺度， σ_T 是用于估计噪声水平的软阈值函数， I 则表示信号样本的总数。

由于不同的受试者之间存在明显的个体差异，他们的睡眠姿势变化也并不一致。即使经过了降噪处理，雷达信号在不同个体上的差异仍然很大，甚至可能出现有人的信号的波峰在其它人那里只是常态数据的情况。为了抹平这种量纲上的差异，本文采用了归一化的预处理方式。完成上述信号预处理步骤后，最后得到的是纯净的，统一的只包含呼吸信息的雷达信号。

2.1.3 基于事件频次分级的细粒度样本标注策略

获得高质量的呼吸信号后，本节进一步对这些信号进行处理，把它们转化为模型训练所需的细粒度标签。在临床实践中，AHI 指标是评估睡眠呼吸暂停整体严重程度的常用方法，也是现有基于 UWB 雷达睡眠呼吸暂停严重程度评估工作的主要依据^[8]。该指标以整夜的总睡眠时长为基准，统计出单位小时内呼吸暂停事件的总频次。文献[8][24]均根据临床 AHI 分级标准，将睡眠呼吸暂停严重程度划分为正常、轻度、中度和重度四个等级。然而，近年来的研究表明，仅依赖整夜 AHI 进行严重程度评估存在一定局限性。文献[30]指出该方式难以充分反映呼吸暂停事件在时间维度上的动态变化特征，因此有必要开展具有更高时间分辨率的严重程度分析。

基于上述认识，本文根据 AHI 分级思想，建立了 2 分钟的观测时间窗口，以实现高时间分辨率的细粒度严重程度分级。具体地，采用滑动窗口把连续的雷达数据分割成长度为 2 分钟的时序片段，并依据各个片段内呼吸暂停事件的发生频次对样本进行标注，通过这种方式能够精准表征睡眠呼吸暂停的严重程度。根据自建数据集的统计分析，绝大部分样本中呼吸暂停事件的频次在 5 以下。因此，为了兼顾系统的精细化评估能力和模型训练的稳定性，本文最终将样本划分为 5 个等级，其中等级 0 代表不包含任何呼吸暂停事件的正常样本，等级 4 表示 2 分钟内发生了大于等于 4 次的严重呼吸暂停事件。

该策略按照临床 AHI 依据事件发生频次进行严重程度分级的思想，将粗粒度的二分类任务转化为细粒度的五分类分级任务。与现有基于整夜 AHI 的分级方法相比，该策略能够量化呼吸暂停严重程度的连续变化，为后续模型训练提供了高质量的细粒度的标注数据。然而等级数量的增加会明显加剧类别分布不平衡问题并增大模型的收敛难度。针对这一问题，本文设计了第 2.2 节所述的双层缓解策略，并将在第 3 章通过实验进一步验证保留五分类设置的必要性。经过上述处理步骤，最终得到的输入数据表示成一个干净的二维信号张量 $X \in \mathbb{R}^{M \times N}$ ，其中 M 表示的是长度为 2 分钟的时间窗口的帧数， N 表示的是距离单元数。该二维数据将输入到后续的网络框架中。

2.2 双层类别不平衡缓解策略

在睡眠呼吸暂停数据集中通常存在严重的类别不平衡问题：正常呼吸的样本数量远远多于异常事件的样本数量。如果直接在此类数据上去训练模型，模型就很容易偏向多数类，这样一来，它对少数类事件的分类性能就会被降低不少。为了解决这一问题，本文提出一种双层缓解策略，从数据层与算法层这两个方面来协同应对类别不平衡问题。

2.2.1 采用随机变换算子的少数类数据增强方法

本文在数据层面上针对少数类样本设计了多样化的增强策略，在原始呼吸信号的时序语义不被破坏的前提下，通过随机变换算子生成新的合成样本，有效扩充了少数类样本的规模，同时提升模型对不同患者呼吸模式个体差异的泛化能力^[31]。在模型训练过程中，本文采用了以下四种变换算子：1) 高斯噪声叠加，在信号中注入微小的随机扰动，来增强模型的抗噪性能。2) 时间平移，在时间轴上随机移动波形，从而增强模型的时序鲁棒性。3) 幅度缩放，在预设范围内对信号幅值进行重新缩放，以此反映出由个体体型差异等其他因素引起的雷达反射强度差异。4) 时间扭曲，在时间维度上对信号进行轻微的压缩或拉伸，用来模拟呼吸速率的自然波动。每一个增强样本 $\tilde{x}_i$ 都是由原始样本 x_i 经过随机组合的增强算子 T 生成的：

$$\tilde{x}_i = T(x_i), T \in \{\text{noise, shift, scale, warp}\} \quad (12)$$

通过上面的方法，本文对少数类的样本进行按比例扩增，其中类别 1 与类别 4 会分别扩增 10 倍和 6 倍。这种扩增的做法能够在不破坏样本内部时序语义的情况下，有效提升少数类样本的多样性。

2.2.2 类别加权损失函数优化方法

虽然在数据层面进行了扩充，但光靠这一点仍然难以彻底解决掉类别分布不均衡这一问题，模型在训练过程中还是可能会出现偏向于识别多数类样本的情况，从而导致对少数类呼吸暂停事件的识别敏感性不足。为此本文在损失函数层面上又做了进一步调整，引入类别加权交叉熵损失函数，不同类别会被分配与其样本频率成反比的权重系数 w_c ，这就相当于是在强制要求模型把针对少数类识别错误所施加的惩罚给加大，具体的权重系数定义如下：

$$w_c = \frac{N}{C \cdot N_c} \quad (13)$$

其中， N_c 表示类别 c 的样本数量， N 表示所有类别的样本总数， C 是类别总数。这种权重机制在训练过程中强调了少数类的重要性，促使模型更加均衡地关注不同严重程度睡眠呼吸暂停样本。最终的损失函数 $\mathcal{L}$ 为：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C w_c y_{i,c} \log(\hat{y}_{i,c}) \quad (14)$$

这里， $y_{i,c}$ 代表的是真实标签， $\hat{y}_{i,c}$ 是模型输出的预测概率分布。这样模型对少数类的误分类就会施加更大的惩罚，

促使模型平等关注各类睡眠呼吸暂停严重程度，显著提升对关键呼吸暂停事件的诊断敏感性。

2.3 混合多尺度形态感知网络




图 3 网络架构

UWB 雷达采集的呼吸信号呈现出复杂的多尺度时序特征，这给高精度建模带来了严峻的挑战。在微观尺度下，波峰与波谷这类局部呼吸形态具有良好的辨识度，但是它们依然容易被高频噪声和突发体动干扰所掩盖。这要求模型具备稳健的局部特征感知能力。而在宏观尺度上，睡眠呼吸暂停事件通常会持续数十秒甚至更长时间，要求模型能够捕获全局时序依赖关系。除此之外，由于呼吸事件的起始与终止边界往往比较模糊，系统必须引入双向上下文信息来准确刻画瞬态事件的演变过程。针对上述挑战，本文设计了 HMSMP-Net 网络架构，其整体框架如图 3 所示。该网络采用了前端局部形态感知、后端全局时序建模的分层设计，协同完成呼吸信号的多尺度特征提取与时序建模。具体而言，针对微观尺度下局部呼吸形态易被噪声干扰的问题，前端利用并行的一维卷积，提取局部的频率特征；针对宏观尺度下呼吸状态演化难以有效建模的问题，后端引入 Mamba 模块，来捕获呼吸信号中的长程时序依赖；针对呼吸事件边界模糊的问题，后端进一步引入 BiGRU，以实现双向边界的精确刻画。通过基于金字塔卷积的局部形态感知与统一的全局上下文序列建模的协同设计，这种结构能把不同时间尺度上的信息都给连接起来，从而让呼吸信号里存在的动态变化能被更完整地表达出来。

2.3.1 局部形态感知：金字塔卷积

为了更加精确地捕捉雷达信号中蕴含的呼吸暂停病理特征，本文在前端引入了金字塔卷积模块来对输入信号进行处理。该模块通过设置不同大小的卷积核(k_1, k_2, k_3)并行工作，对于输入信号 $X \in \mathbb{R}^{L \times L}$ 进行多分辨率频率分解，不同

尺度下的特征能够被同时提取并进行融合。多尺度特征融合过程表示为：

$$\mathbf{H}_{ms} = \text{ReLU}(\text{BN}(\text{Concat}(\text{Conv1D}_{k_1}(\mathbf{X}), \text{Conv1D}_{k_2}(\mathbf{X}), \text{Conv1D}_{k_3}(\mathbf{X})))) \quad (15)$$

这一并行结构跟雷达生理信号的物理特性十分契合。小尺寸卷积核捕获高频局部变化，大尺寸卷积核提取低频呼吸包络。通过融合多尺度特征，再结合批归一化（BN, batch normalization）来实现幅值标准化，随后这些特征会被输入到 Mamba^[32]模块里，用于后续的全局时序建模。

2.3.2 全局建模：选择性状态空间与双向语义

呼吸暂停事件通常都有较长的时间跨度，如果只依赖局部范围内的特征进行建模，系统就很难把它的动态变化过程给完整地表达出来。为了能够高效捕获到长程时序依赖关系，本文引入了基于选择性状态空间模型的 Mamba^[32]架构。Mamba 能通过选择性扫描机制来对序列进行处理，在医疗信号分析和雷达信号处理任务中已经展现出优越的长程依赖建模能力^[33-35]。在输入阶段每个 Mamba 块都采用零阶保持（ZOH, zero-order hold）方法进行离散化处理：

$$\bar{\mathbf{A}} = \exp(\Delta \mathbf{A}) \quad (16)$$

$$\bar{\mathbf{B}} = (\Delta \mathbf{A})^{-1} (\exp(\Delta \mathbf{A}) - \mathbf{I}) \cdot \Delta \mathbf{B} \quad (17)$$

其中， Δ 为离散化步长。离散化后系统的状态更新过程可描述为：

$$\mathbf{h}_k = \bar{\mathbf{A}} \mathbf{h}_{k-1} + \bar{\mathbf{B}} \mathbf{x}_k \quad (18)$$

$$\mathbf{y}_k = \mathbf{C} \mathbf{h}_k \quad (19)$$

其中， $\mathbf{x}_k \in \mathbb{R}$ 为第 k 个时间步的输入标量， $\mathbf{h}_k \in \mathbb{R}^N$ 表示隐藏状态向量， $\mathbf{y}_k \in \mathbb{R}$ 是输出标量， $\mathbf{C} \in \mathbb{R}^{1 \times N}$ 为输出矩阵。

为提升训练并行效率，将上述递归计算转化为全局卷积形式。在实际实现中，提取的特征图被输入到 Mamba 模块中，通过门控时空交互机制进行处理。计算过程为：

$$\mathbf{X}_1 = \text{LN}(\text{SSM}(\text{SiLU}(\text{DWConv}(\text{Linear}(\mathbf{X})))) \quad (20)$$

$$\mathbf{X}_2 = \text{SiLU}(\text{Linear}(\mathbf{X})) \quad (21)$$

$$\mathbf{X}_{\text{out}} = \text{Linear}(\mathbf{X}_1 \odot \mathbf{X}_2) \quad (22)$$

其中， $\text{Linear}(\cdot)$ 用于通道维度的线性映射， $\text{DWConv}(\cdot)$ 表示一维深度可分离卷积， $\text{SiLU}(\cdot)$ 是激活函数， $\text{SSM}(\cdot)$ 为核心的选择性扫描状态空间模块，负责全局上下文建模， $\text{LN}(\cdot)$ 表示层归一化操作， $\odot$ 为逐元素乘法。

Mamba 采用单向扫描机制，难以利用未来时刻信息，而呼吸事件的边界往往并不清晰，其判别往往需要事件结束后的恢复性呼吸模式。为了能显式地把反向的时序上下文给引入进来，同时也为了弥补单向建模带来的不足，本文将 Mamba 模块的输出 $\mathbf{H}_{mamba} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_L]$ 输入至 BiGRU，分别计算出前向隐状态与后向隐状态：

$$\bar{\mathbf{h}}_t = \text{GRU}_f(\mathbf{h}_t, \bar{\mathbf{h}}_{t-1}) \quad (23)$$

$$\tilde{\mathbf{h}}_t = \text{GRU}_b(\mathbf{h}_t, \tilde{\mathbf{h}}_{t+1}) \quad (24)$$

并通过拼接两个方向的隐状态，获得最终上下文表示：

$$\mathbf{H}_{\text{bi}} = [\bar{\mathbf{h}}_t; \tilde{\mathbf{h}}_t] \quad (25)$$

其中， $\bar{\mathbf{h}}_t$ 与 $\tilde{\mathbf{h}}_t$ 分别代表来自不同时间方向的序列上下文信息。通过这些模块的共同作用，HMSMP-Net 能够同时学习局部形态变化、长时动态演化以及未来恢复上下文，从而实现睡眠呼吸暂停细粒度严重程度的高精度分类。

3 实验设计及性能分析

为了验证所提方法 FG-SAD 的有效性，本章介绍了临床数据集构建以及实验结果分析，本文将 FG-SAD 方法与现有主流方法进行了对比，同时还做了消融实验和超参数分析，进一步证实所提方法的有效性。

3.1 数据集




图 4 实验场景的布局 and 设置

为了实现细粒度睡眠呼吸暂停检测任务，本文建立了一个基于 UWB 雷达的睡眠呼吸暂停数据集，所有数据均来自于安徽医科大学第二附属医院开展的临床试验，信号采集场景如图 4 所示。实验采用 AW-UWB-EV-02 型 UWB 雷达作为采集设备，工作频率范围是 7.29GHz 到 8.75GHz，设备连续工作时间超过 24 小时，可以完整覆盖受试者的整个睡眠周期。实验过程中，本文将雷达的发射天线和接收天线都指向受试者的胸腔，同时要求受试者佩戴 PSG 电极以获取精确的标注信息。本文一共招募了 11 名受试者参与了数据收集，包括了 10 名被诊断患有睡眠呼吸暂停综合征的患者和 1 名健康受试者，年龄均匀分布在 20 岁至 50 岁之间。本文所有实验都在医院环境中的专用的睡眠状态监测室中进行，对每个受试者都进行整夜的睡眠健康监测。最终一共收集了约 57.2 个小时的睡眠数据，并分割为 608 个不同的样本，其中的 PSG 数据由专业医师进行标注，得到的结果作为真实标签。该数据集构建了面向短时瞬态严重程度的细粒度标签，为基于 UWB 雷达的细粒度睡眠呼吸暂停研究提供了临床数据基础。表 1 展示了这些样本的具体统计情况。可以清楚地观察到，类别为 0 的样本数量超过了样本总数的 60%，而类别 1 和类别 4 的样本数量则明显偏少。这种类别分布不平衡的特性会让模型在训练过程中容易偏向多数类，从而削弱了它对关键呼吸暂停事件的识别能力，本文在第 2.2 节中设计的双层缓解策略能够解决这一挑战。

表 1 数据集构成和各受试者呼吸暂停事件分布						
受试者	总计	严重程度类别				
		0	1	2	3	4
受试者 1	98	97	1	0	0	0
受试者 2	15	1	2	12	0	0
受试者 3	82	13	0	10	42	17
受试者 4	115	115	0	0	0	0
受试者 5	56	54	2	0	0	0
受试者 6	8	0	0	5	3	0
受试者 7	114	1	0	65	48	0
受试者 8	71	53	5	6	6	1
受试者 9	39	32	0	3	4	0
受试者 10	9	4	0	2	3	0
受试者 11	1	0	1	0	0	0
总计	608	370	11	103	106	18

3.2 评估准则

为了评估模型的分类性能，本文选取准确率（Acc, accuracy）、宏平均 F1 分数（Macro F1-score）和加权平均

F1 分数（Weighted F1-score）作为评估指标。需要说明的是，在五分类任务中微平均 F1 分数（Micro F1-score）等同于准确率，本文用准确率代替了微平均 F1 分数。鉴于数据集中存在严重的类别不平衡问题，本文把宏平均 F1 分数作为主要评估指标，在该指标下各类别权重相同，能够更直接地反映模型对少数类的诊断敏感性。准确率和加权平均 F1 分数则提供了与自然数据分布相一致的综合性评估。为全面评估模型的泛化性能，采用五折交叉验证进行实验。即将整个数据集随机划分成 5 个互不重叠的子集，每轮实验选取其中一个子集作为测试集。模型采用第 2.2.2 节所述的加权交叉熵损失函数，并利用 AdamW 优化器对模型参数进行迭代更新。整个训练过程共包含 100 个轮次，必要时采用早停法。学习率设定为 $3e-4$ ，权重衰减系数设定为 $5e-5$ ，批大小为 16。所有实验均在单张 NVIDIA RTX 3090 GPU 上使用 PyTorch 框架完成。

3.3 总体性能

为了全面评估所提方法 FG-SAD 在睡眠呼吸暂停检测任务上的性能，本节用以下的主流方法作为对比基准：Conv1D、BiGRU、双向长短期记忆网络（BiLSTM, bi-directional long short-term memory）、基于 CNN-Transformer 架构的 OSA-AI^[8]以及基于 SSM 的 AIR-Mamba^[33]，所有方法在自建数据集上的性能表现如表 2 所示。

表 2 不同方法的性能比较			
方法	Acc	Macro F1-score	Weighted F1-score
Conv1D	88.51 ± 1.56**	74.01 ± 2.90	89.26 ± 1.30*
BiGRU	89.36 ± 1.50***	79.57 ± 1.73	90.06 ± 0.94
BiLSTM	89.36 ± 3.75	77.86 ± 3.05	90.14 ± 2.66
OSA-AI	72.13 ± 8.00*	55.33 ± 10.57*	71.38 ± 6.98*
AIR-Mamba	82.98 ± 3.32*	72.25 ± 5.20*	83.02 ± 3.15*
FG-SAD (本文方法)	92.34 ± 1.85	82.06 ± 1.13	92.16 ± 1.82

注：加粗项表示最优结果。*、**、***分别表示 FG-SAD 与各方法之间差异达到 $p<0.05$ 、 $p<0.01$ 和 $p<0.001$ 的统计显著性。

FG-SAD 在各项指标上均取得了最佳性能，其中准确率达到 92.34%，宏平均 F1 分数为 82.06%，加权平均 F1 分数为 92.16%，与其他主流时序建模方法相比，本文方法在细粒度分类任务中表现出更优的稳定性和准确性。基于 CNN-Transformer 架构的 OSA-AI 方法性能表现相对较弱，准确率仅为 72.13%，说明纯注意力机制在这类任务中的适应性有待提升，而 AIR-Mamba 方法的准确率达到 82.98%，较 OSA-AI 有明显提升，但整体性能未能达到 FG-SAD 的水平。相比之下，FG-SAD 在长程依赖关系的建模上做得更好，显著提高模型的准确率。配对 t 检验结果表明，FG-SAD 与 Conv1D、BiGRU、OSA-AI 和 AIR-Mamba 在准确率上的差异均达到统计显著水平 ($p<0.05$)，与 BiLSTM 的差异未达到显著水平，但 Cohen’s $d=1.01$ 属大效应量，所有对比的效应量均大于 0.8。这表明 FG-SAD 相较于现有方法获得的性能提升具有统计学意义。另外需要指出的是，细粒度分类任务中的睡眠呼吸暂停数据本身就存在类别不平衡的问题，所以宏平均 F1 分数通常会略低于准确率，这种情况在医学数据分析中比较常见。不过 FG-SAD 仍然保持了较高的宏平均 F1 分数和加权平均 F1 分数，这足以说明模型在处理好类别不平衡问题的同时，也具备了很强的鲁棒性以及泛化能力。




图 5 FG-SAD 在五分类睡眠呼吸暂停检测任务上的混淆矩阵与 ROC 曲线

为了进一步分析 FG-SAD 在不同严重程度类别上的识别表现，图 5 给出了模型在五分类任务上的混淆矩阵和真阳性率-假阳性率曲线（ROC 曲线）。从图 5(a) 可以看出，多数样本集中于对角线，说明 FG-SAD 能够较准确地区分不同严重程度类别。其中，类别 0 的识别效果最好，而类别 1 由于样本最少，识别难度最高，但在双层缓解策略作用下仍保持较好的识别效果，与表 4 的少数类分析结果一致。从图 5(b) 可以看出，FG-SAD 在各类别上均取得了较高的曲线下面积（AUC, area under the curve）值，类别 0、2、3、4 的 AUC 均超过 0.96。即使是样本量最少的类别 1，其 AUC 仍达到 0.8120，表明模型在类别不平衡条件下仍具有较好的少数类区分能力。这说明本文提出的双层缓解策略能够有效缓解类别不平衡带来的影响。其中，数据增强扩充了少数类样本分布，使其在训练中不再被模型忽视；类别加权提高了少数类样本的贡献，进一步增强了对少数类样本的关注。上述结果表明，FG-SAD 在类别不平衡条件下仍具有良好的类别区分能力和少数类识别能力。

3.4 消融实验

为严格评估 FG-SAD 方法中每个模块和训练策略的贡献，本文进行了全面的消融实验，把各个模块单独从框架中移除，一共评估了下面这五种变体：

- (1) FG-SAD w/o 金字塔局部形态感知模块：移除基于金字塔卷积的局部形态感知前端模块；
- (2) FG-SAD w/o Mamba：移除全局上下文建模后端中的 Mamba 模块；
- (3) FG-SAD w/o BiGRU：移除全局上下文建模后端中的 BiGRU 模块；
- (4) FG-SAD w/o 数据增强：移除数据增强策略，仅使用原始数据进行训练；
- (5) FG-SAD w/o 类别加权：移除类别加权策略，采用标准交叉熵损失进行训练。

实验结果汇总于表 3，各组成模块均能够提升模型性能。其中，移除 Mamba 后性能下降最明显，准确率直接下降了 5.11%，宏平均 F1 分数下降 6.70%，说明长程时序建模是提升性能的关键因素；移除金字塔局部形态感知模块后，宏平均 F1 分数下降 3.02%，表明了局部空间特征提取对模型性能有一定的影响。移除 BiGRU 模块后，模型整体性能下降，表现双向时序信息能够帮助模型理解呼吸信号的变化。此外，去除数据增强或类别加权策略后，宏平均 F1 分数分别下降 2.34%和 1.48%，说明双层缓解策略能够有效提升少数类识别能力。

表 3 本文方法的消融实验

方法	Acc	Macro F1-score	Weighted F1-score
FG-SAD	92.34±1.85	82.06±1.13	92.16±1.82
FG-SAD w/o 金字塔局部形态感知模块	91.91±3.77	79.04±5.30	91.81±2.58
FG-SAD w/o Mamba	87.23±3.56*	75.36±5.04*	88.52±2.61*
FG-SAD w/o BiGRU	90.64±1.41*	80.36±3.69	90.67±1.37*
FG-SAD w/o 数据增强	91.06±4.11	79.72±6.52	91.18±3.72
FG-SAD w/o 类别加权	91.06±2.46	80.58±7.25	90.82±2.28

注：加粗项表示最优结果。*表示 FG-SAD 与各消融变体之间差异达到 p<0.05 的统计显著性。

为分析双层缓解策略对少数类样本的影响，表 4 列出了不同训练策略下类别 1 和类别 4 的精确率、召回率和 F1 分数。可以看出，不加任何策略时，模型对少数类样本的识别能力较弱。单独使用数据增强或类别加权时，各类指标有明显提升。两者结合后，FG-SAD 在少数类别上均取得了最佳性能，类别 1 和类别 4 的 F1 分数分别提升至 0.5934 和 0.7756。这说明两者的共同作用能够有效缓解细粒度睡眠呼吸暂停检测中的类别分布不平衡问题。

表 4 双层缓解策略对少数类的影响

	不使用双层缓解策略		只采用数据增强		只采用类别加权		使用双层缓解策略	
	类别 1	类别 4	类别 1	类别 4	类别 1	类别 4	类别 1	类别 4
精确率	0.4000	0.6667	0.7000	0.8100	0.6667	0.6033	0.7600	0.8200
召回率	0.2000	0.5000	0.5333	0.5833	0.5333	0.7000	0.6333	0.7667
F1 分数	0.2667	0.5714	0.5800	0.6411	0.5610	0.6376	0.5934	0.7756

为进一步验证在当前数据分布条件下保留五分类设置的必要性，本文构建了三分类对照实验，将类别 1 与类别

2、类别 3 与类别 4 分别合并，在相同设置下进行五折交叉验证，结果如表 5 所示。可以看出，三分类任务由于类别数量减少、类别边界更加明显，因此取得了略高的分类性能。然而，准确率仅较五分类提高了 0.85 个百分点，且由于分类粒度明显降低，无法提供更丰富的严重程度层次信息。为进一步分析五分类新增严重程度层级的实际区分能力，结合图 5(a) 的混淆矩阵进行分析。类别 2 的 103 个样本中有 96 个被正确识别，类别 3 的 106 个样本中有 91 个被正确识别，且误分类主要发生在相邻类别之间，表明五分类的严重程度层级在实际分类中具有较好的可区分性。若合并为三分类，相邻等级之间的差异将被直接消除。因此，五分类能够保留更多短时严重程度层次信息，更符合本文细粒度睡眠呼吸暂停检测的研究目标。

分类粒度	Acc	Macro F1-score	Weighted F1-score
三分类	93.19±1.59	91.61±2.13	93.10±1.69
五分类（本文）	92.34±1.85	82.06±1.13	92.16±1.82

注：三分类将类别 1、2 合并为中度类别，将类别 3、4 合并为重度类别。

3.5 超参数分析

为验证双层缓解策略在细粒度严重程度分级中应对类别不平衡的有效性，图 6 从数据增强与加权损失两个层面对整体性能进行了分析。图 6(a) 和图 6(b) 展示了单一增强算子和增强算子数量对网络性能的影响，其中，增强结果采用所有组合方式的平均值。可以观察到，单一增强学习到的呼吸模式相对有限，组合多种策略后能够学习到更加丰富的时序特征。图 6(c) 分析了加权损失函数中权重系数 α 对模型性能的影响。当 α 过小时，对少数类关注不足；当 α 过大时，模型容易过度关注少数类，导致整体泛化性能下降。此外，图 6(d) 重点研究了两个最严重的少数类别在合成增强因子 (A_1, A_4) 变动时的敏感程度。实验结果显示，增强因子过小会导致少数类样本没能得到充分的扩充，而增强因子过大会引入不少噪声，影响模型训练。当增强因子配置为 (10,6) 时，FG-SAD 取得了最佳性能，这说明了适当规模的合成增强因子能够调整好类别分布，让网络在学习过程中能够更加关注少数类，同时也避开了由于过度扩展而带来的过拟合问题，使得整体的性能表现保持稳定。实验结果表明，本文提出的双层缓解策略能够缓解临床数据中普遍存在的类别不平衡的问题，并显著提升了本文方法在细粒度睡眠呼吸暂停分类任务中的性能。




图 6 双层缓解策略的超参数分析

4 结束语

本文提出 FG-SAD, 一种基于 UWB 雷达的非接触式的细粒度睡眠呼吸暂停监测方法。与传统的监测方法不同, FG-SAD 根据短时窗口内呼吸暂停事件的发生频次, 对样本进行不同严重程度等级的标注, 将二分类监测任务拓展为五分类的精细化量化任务。针对临床数据中普遍存在的类别不平衡问题, 本文设计了一种双层缓解策略, 将少数类数据增强与类别加权损失相结合。在模型架构上, 本文设计了一种混合多尺度形态感知网络 HMSMP-Net。该网络利用金字塔卷积提取不同时间尺度下的局部呼吸形态特征, 并结合全局上下文建模模块, 以增强对复杂呼吸模式的表征能力。基于自建 UWB 睡眠呼吸暂停数据集的实验结果显示, FG-SAD 的分类准确率为 92.34%, 宏平均 F1 分数为 82.06%, 显著优于现有的基线方法。本文不仅验证了 FG-SAD 在细粒度睡眠呼吸监测任务中的有效性, 也为居家场景下实现非接触式的高精度睡眠健康监测提供了一种可行方案。

参考文献


- [1] LIU X, WANG X, HUANG J, et al. Class-imbalanced graph contrastive clustering for sleep apnea prediction in mental health[J]. *Pattern Recognition*, 2026, 176: 113157.
- [2] DALGAARD F, NORTH R, PIEPER K, et al. Risk of major cardiovascular and neurologic events with obstructive sleep apnea among patients with atrial fibrillation[J]. *American Heart Journal*, 2020, 223: 65–71.
- [3] BAILLIEUL S, DEKKERS M, BRILL A K, et al. Sleep apnoea and ischaemic stroke: current knowledge and future directions[J]. *The Lancet Neurology*, 2022, 21(1): 78–88.
- [4] CUI F Q, HUANG J, ZHAO S, et al. PersoMoni: A Comprehensive Video-Based Benchmark Dataset for Fine-grained Personality Assessment with 15 Trait Dimensions[J]. *IEEE Transactions on Affective Computing*, 2026.
- [5] JAVAHERI S, PEKER Y, YAGGI H K, et al. Obstructive sleep apnea and stroke: The mechanisms, the randomized trials, and the road ahead[J]. *Sleep Medicine Reviews*, 2022, 61: 101568.
- [6] YEGHIAZARIANS Y, JNEID H, TIETJENS J R, et al. Obstructive sleep apnea and cardiovascular disease: a scientific statement from the American Heart Association[J]. *Circulation*, 2021, 144(3): e56–e67.
- [7] MALHOTRA A, AYAPPA I, AYAS N, et al. Metrics of sleep apnea severity: beyond the apnea-hypopnea index[J]. *Sleep*, 2021, 44(7): zsab030.
- [8] CHOI J W, KOO D L, KIM D H, et al. A novel deep learning model for obstructive sleep apnea diagnosis: Hybrid CNN-transformer approach for radar-based detection of apnea-hypopnea events[J]. *Sleep*, 2024, 47(12): zsa184.
- [9] LI Y, DONG S, AND GU C. Feel your heartbeat across space: Radar-based cardiac activity monitoring for healthcare applications[J]. *IEEE Microwave Magazine*, 2024, 25(12): 91–111.
- [10] KOU H, WANG H, CHENG R, et al. Smart pillow based on flexible and breathable triboelectric nanogenerator arrays for head movement monitoring during sleep[J]. *ACS Applied Materials & Interfaces*, 2022, 14(20): 23998–24007.
- [11] AHMADZADEH S, LUO J, AND WIFFEN R. Review on biomedical sensors, technologies and algorithms for diagnosis of sleep disordered breathing: Comprehensive survey[J]. *IEEE Reviews in Biomedical Engineering*, 2020, 15: 4–22.
- [12] GU Y, GAGNON J F, AND KAMINSKA M. Sleep electroencephalography biomarkers of cognition in obstructive sleep apnea[J]. *Journal of Sleep Research*, 2023, 32(5): e13831.
- [13] HE C, WANG X, WEN Y, et al. Sleep monitoring and sleep-aid intervention methods: A review[J]. *IEEE Internet of Things Journal*, 2025, 12(16): 32780–32795.
- [14] 黄锦阳, 崔丰麒, 马长秀, 等. 基于通用手环的睡眠呼吸暂停检测[J]. *计算机应用*, 2025, 45(9): 3045–3056.
HUANG JINYANG, CUI FENG-QI, MA CHANGXIU, et al. Sleep apnea detection based on universal wristband[J]. *Journal of Computer Applications*, 2025, 45(9): 3045–3056.
- [15] YIN M, HADJIPANAYI C, RAVINDRAN K K, et al. Unobtrusive sleep health assessment using impulse radar: A pilot study in older people[J]. *IEEE Transactions on Biomedical Engineering*, 2025, 72(9): 2663–2674.
- [16] 饶翀, 姜夕康, 郭嘉航, 等. 基于大语言模型的超宽带雷达多任务学习方法[J/OL]. *物联网学报*, 2026.
RAO CHONG, JIANG XIKANG, GUO JIAHANG, et al. UWB-LLM: ultra-wideband radar multi-tasking based on large language model[J/OL]. *Chinese Journal on Internet of Things*, 2026.
- [17] WANG M, HUANG J, ZHANG X, et al. Target-oriented WiFi sensing for respiratory healthcare: from indiscriminate perception to in-area sensing[J]. *IEEE Network*, 2025, 39(5): 201–208.
- [18] TAKBIRI M AND TAHERZADEH M. Accurate behind-the-wall respiration detection using low-complexity frequency-searching time-domain UWB pulse radar[J]. *IEEE Transactions on Instrumentation and Measurement*, 2026, 75: 8505511.
- [19] HASAN K, EBRAHIM M P, XU H, et al. Analysis of spectral estimation algorithms for accurate heart rate and respiration rate estimation using an ultra-wideband radar sensor[J]. *IEEE Reviews in Biomedical Engineering*, 2022, 17: 297–309.
- [20] 吴彤, 李业深, 黄镇煌, 等. 一种行人遮挡下的 UWB 非视距传播识别方法[J]. *物联网学报*, 2023, 7(4): 63–71.
TONG WU, YESHEN LI, ZHENHUANG HUANG, et al. A UWB NLOS identification method under pedestrian occlusion[J]. *Chinese Journal on Internet of Things*, 2023, 7(4): 63–71.

- [21] CHERAGHINIA M, SHAHID A, LUCHIE S, et al. A comprehensive overview on UWB radar: Applications, standards, signal processing techniques, datasets, radio chips, trends and future research directions[J]. IEEE Communications Surveys & Tutorials, 2025, 27(4): 2283-2324.
- [22] LI Q, LIU J, GRAVINA R, et al. A uwb-radar-based adaptive method for in-home monitoring of elderly[J]. IEEE Internet of Things Journal, 2023, 11(4): 6241-6252.
- [23] CHEN Z, CHENG R, CHEN K, et al. A new self-supervised learning method for sleep apnea detection from radar signals[C]. Proceedings of the 4th International Conference on Biomedical and Intelligent Systems, 2025: 39–43.
- [24] ZHOU Y, SHU D, XU H, et al. Validation of novel automatic ultra-wideband radar for sleep apnea detection[J]. Journal of thoracic disease, 2020, 12(4): 1286.
- [25] EOM J Y, JEON W S, AND JEONG D G. Uwb impulse radar-based open-set gesture recognition using transformer and one-versus-rest classifier[J]. IEEE Internet of Things Journal, 2025, 12(13): 24803-24818.
- [26] 曾文敏, 郑柏烽, 刘晋廷, 等. 非视距条件下基于特征融合的 UWB 到达角估计方法[J]. 物联网学报, 2025, 09(04):51-61.
ZENG WENMIN, ZHENG BOFENG, LIU JINTING, et al. Feature fusion method for UWB angle of arrival estimation under non-line-of-sight conditions[J]. Chinese Journal on Internet of Things, 2025, 09(04):51-61.
- [27] KHODARAHMI M AND MAIHAMI V. A review on Kalman filter models[J]. Archives of Computational Methods in Engineering, 2023, 30(1): 727-747.
- [28] HUANG J, LIU B, MIAO C, et al. Phyfinatt: An undetectable attack framework against phy layer fingerprint-based wifi authentication[J]. IEEE Transactions on Mobile Computing, 2023, 23(7): 7753-7770.
- [29] WANG Y, LIU N, PAN Z, et al. Rf fingerprint recognition based on adaptive wavelet threshold denoising[C]. 2024 IEEE/CIC International Conference on Communications in China (ICCC), 2024: 337-342.
- [30] OKSENBERG A, LEPPÄNEN T. Duration of respiratory events in obstructive sleep apnea: in search of paradoxical results[J]. Sleep Medicine Reviews, 2023, 68: 101728.
- [31] HUANG J, FENG Y, CUI F Q, et al. Identifying who you are no matter what you write through abstracting handwriting style[J]. IEEE Transactions on Dependable and Secure Computing, 2026, 23(3): 6890-6905.
- [32] GU A AND DAO T. Mamba: Linear-time sequence modeling with selective state spaces[EB/OL]. 2023.
- [33] LI S, DONG X, FAN Y, et al. Domain-adaptive UAV recognition using IR-UWB radar and a lightweight Mamba-based network[J]. IEEE Sensors Journal, 2025, 25(18): 34913-34926.
- [34] WANG T, SHU Y, QIAO L, et al. LightMamba: a resource-efficient deep learning method for UWB NLOS identification based on selective state-space modeling[J]. IEEE Internet of Things Journal, 2026, 13(5): 8735-8748.
- [35] ZHANG Z, WEN Y, LIANG W, et al. Mamba-HTEPA: a multi-branch structure framework for multimodal grading of meningiomas using Mamba[J]. Expert Systems with Applications, 2026: 132689.

[作者简介]



贺蓓（2002—），女，合肥工业大学硕士生，主要研究方向为雷达生理感知、无线感知等。



黄锦阳（1994—），男，博士，合肥工业大学副教授，主要研究方向为多模态人因感知、人机交互、无线安全以及信号处理等。



刘鑫（1993—），男，合肥工业大学博士生，主要研究方向为计算机视觉、图对比学习和无线感知等。



赵鹏（1998- ），男，合肥工业大学博士生，主要研究方向为智能信息处理、无线感知和机器学习等。



崔丰麒（2001- ），男，中国科学技术大学博士生，主要研究方向为情感计算、人工智能等。



郭宇童（2003- ），男，合肥工业大学硕士生，主要研究方向为雷达生理感知、无线感知等。



王萌（1998- ），女，合肥工业大学博士生，主要研究方向为智能信息处理、无线感知和机器学习等。



黎歆雨（1999- ），女，合肥工业大学博士生，主要研究方向为智能信息处理、无线感知和机器学习等。



赵思蕊（1991- ），男，博士，中国科学技术大学副研究员，主要研究方向为情感计算、多模态理解、人机交互等。